

ARTÍCULO

A. *Robust LOESS*

Esta técnica de reducción de ruido mediante ajuste de tendencia tiene como objetivo suavizar los datos, reduciendo el impacto de valores atípicos o ruidos. Esto implica que, en primer lugar, se ajustan los datos para luego minimizar la influencia de aquellos puntos anormales en el conjunto general [1]. De este modo, la técnica combina regresión local y ponderación robusta, asignando pesos más bajos a los puntos alejados de la mayoría, lo cual disminuye su impacto en el ajuste final y permite que la tendencia refleje con mayor precisión los datos principales. Además, esta metodología forma parte de un grupo de métodos de suavizado, entre los que se encuentran LOESS y LOWESS. En el caso de LOESS, se emplean tanto polinomios lineales como de grado superior, logrando así un ajuste flexible y detallado que se adapta mejor a tendencias complejas. Por otro lado, LOWESS es una variante particular de LOESS que utiliza únicamente ajustes lineales, siendo ideal para modelar relaciones simples y lineales en los datos [1].

El término "Robust" se refiere a cómo el método maneja el peso de cada dato en el proceso de suavizado. En métodos de suavizado sin robustez, cada dato contribuye con su peso completo, independientemente de su lejanía respecto a la tendencia general, lo que puede distorsionar el ajuste. Al aplicar un enfoque robusto, se reduce el peso de los puntos atípicos en función de su distancia respecto a la tendencia, llegando incluso a asignarles un peso de cero si están demasiado alejados. Este ajuste iterativo de pesos minimiza la influencia de los valores atípicos y mejora la precisión del suavizado, permitiendo una representación más fiel de la tendencia subyacente en los datos [1].

Procedimiento: En primer lugar, se define una ventana que contiene un subgrupo de datos. Esta ventana se centra en un punto específico y abarca una cantidad simétrica de puntos alrededor de él, cuyo tamaño se ajusta según el nivel de detalle deseado en el suavizado [1]. A continuación, se asignan pesos a cada uno de los puntos en la ventana, basados en su cercanía al centro; los puntos más cercanos tienen un peso mayor, mientras que los más alejados reciben un peso menor. Posteriormente, se ajusta una línea de tendencia, teniendo en cuenta los pesos asignados a cada punto. Este ajuste puede ser lineal o polinomial, dependiendo del nivel de complejidad necesario [1]. A partir de este ajuste inicial, se calculan los residuos, que representan la diferencia entre los valores originales de los puntos y los valores ajustados en la línea de tendencia, indicando qué tan lejos se encuentran de la curva de suavizado.

Finalmente, se aplica la fase robusta de la metodología: se recalculan los pesos en función de los residuos obtenidos, de modo que los puntos con residuos grandes (valores atípicos) reciben un peso mucho menor o incluso nulo, mientras que los puntos cercanos a la tendencia general conservan un peso alto [1]. Este proceso de refinamiento asegura que los valores atípicos tengan un impacto mínimo, resultando en una curva de tendencia que representa de manera más precisa la estructura subyacente de los datos.

Código:

```
import numpy as np

import matplotlib.pyplot as plt

import statsmodels.api as sm

# Generar datos simulados
```

```

np.random.seed(0)

x = np.linspace(0, 10, 100)

y = np.sin(x) + np.random.normal(scale=0.3, size=len(x))

# Aplicar suavizado LOESS robusto

lowess = sm.nonparametric.lowess(y, x, frac=0.2, it=3) # 'frac'
               controla el tamaño de la ventana, 'it' para robustez

# Graficar los resultados

plt.scatter(x, y, label='Datos con ruido')

plt.plot(lowess[:, 0], lowess[:, 1], color='red', label='Robust LOESS',
         linewidth=2)

plt.xlabel('x')

plt.ylabel('y')

plt.title('Suavizado Robust LOESS')

plt.legend()

plt.show()

```

B. *Non Local Means.*

El método Non-Local Means (NLM) es una técnica avanzada de reducción de ruido en imágenes que se diferencia claramente de otros métodos convencionales. A diferencia de las técnicas tradicionales que suelen trabajar con regiones pequeñas y adyacentes de píxeles, NLM identifica píxeles con patrones similares, independientemente de su proximidad al píxel objetivo [1]. Así, en lugar de comparar cada píxel individualmente, este método analiza bloques o "parches" de píxeles cercanos, lo cual facilita el proceso de suavizado. De esta manera, los píxeles que son altamente similares al píxel objetivo reciben un mayor peso en el ajuste, mientras que los menos similares tienen una influencia reducida, minimizando así su efecto en el resultado final.

Procedimiento: Para aplicar el método, primero se define una ventana de vecindad alrededor del píxel objetivo, la cual es un pequeño bloque de píxeles que representa el contexto cercano al píxel. Luego, se establece una ventana de búsqueda mucho más amplia, que abarca una porción mayor de la imagen [1]. El propósito de esta

ventana de búsqueda es examinar una variedad de bloques en la imagen que podrían ser similares al bloque central del píxel objetivo . A continuación, dentro de esta ventana de búsqueda, se compara la vecindad del píxel objetivo con las vecindades de los demás píxeles en esa área. Mediante esta comparación, se mide la similitud en cuanto a patrones de color y textura, permitiendo identificar aquellas vecindades que comparten características estructurales similares [1]. Así, el algoritmo puede enfocarse en los patrones coincidentes en lugar de simplemente promediar píxeles cercanos [1].

Una vez identificadas las áreas similares, se procede a asignar pesos a cada píxel en la ventana de búsqueda en función de su similitud con el píxel objetivo. Los píxeles con vecindades similares reciben un peso más alto, lo que los hace más influyentes en el proceso de suavizado. Por otro lado, aquellos píxeles que muestran menor similitud obtienen pesos bajos o incluso cero, de modo que su impacto en el valor final es mínimo o nulo [1].

Finalmente, se calcula el valor del píxel central mediante un promedio ponderado de los valores de los píxeles en la ventana de búsqueda, utilizando los pesos asignados. Esto permite que el método reduzca el ruido sin comprometer detalles importantes de la imagen, ya que solo los píxeles con patrones similares contribuyen significativamente al valor del píxel suavizado [1].

Código:

```
import numpy as np

import matplotlib.pyplot as plt

from skimage import data

from skimage.restoration import denoise_nl_means, estimate_sigma

from skimage import img_as_float

# Cargar una imagen de ejemplo a color (puedes usar cualquier imagen RGB)

image = data.coffee() # Imagen de ejemplo a color

# Convertir la imagen a float64 (para evitar problemas con el rango de valores de píxeles)

image = img_as_float(image)

# Agregar más ruido gaussiano a la imagen para que la diferencia sea visible

np.random.seed(0)
```

```

noisy_image = image + 0.3 * np.random.standard_normal(image.shape) #
Ruido más fuerte

# Asegurarnos de que los valores estén dentro del rango [0, 1]

noisy_image = np.clip(noisy_image, 0, 1)

# Estimación del ruido (sigma) para cada canal de la imagen

sigma_est = np.mean([estimate_sigma(noisy_image[:, :, i]) for i in
range(3)])

# Aplicar Non-Local Means (NLM) para cada canal de la imagen con
parámetros ajustados

denoised_image = np.zeros_like(noisy_image)

for i in range(3): # Procesar cada canal (R, G, B) por separado

    denoised_image[:, :, i] = denoise_nl_means(noisy_image[:, :, i],
h=1.5 * sigma_est, sigma=sigma_est, fast_mode=True, patch_size=7,
patch_distance=11)

# Mostrar los resultados

fig, axes = plt.subplots(1, 3, figsize=(12, 6))

ax = axes.ravel()

ax[0].imshow(image)

ax[0].set_title('Imagen original')

ax[0].axis('off')

```

```
ax[1].imshow(noisy_image)

ax[1].set_title('Imagen con ruido')

ax[1].axis('off')


ax[2].imshow(denoised_image)

ax[2].set_title('Imagen denoised (NLM) ')

ax[2].axis('off')


plt.tight_layout()

plt.show()
```

INTRODUCCIÓN

El análisis estadístico de las enfermedades cardíacas, como la fibrilación auricular (AFIB) y la bradicardia sinusal (SB), proporciona información valiosa sobre los parámetros clínicos asociados con estas condiciones, así como su interpretación y relación con la fisiopatología correspondiente. Estos análisis permiten identificar patrones y características que son fundamentales para el diagnóstico y tratamiento de las enfermedades cardíacas [2].

Uno de los parámetros fundamentales en el análisis de las enfermedades cardíacas es la frecuencia cardíaca. La evaluación en el dominio frecuencial, que emplea técnicas como la Transformada de Fourier y el análisis espectral, ofrece una comprensión detallada de la dinámica de los impulsos eléctricos en el corazón [2]. Mediante estos enfoques, es posible descomponer las señales eléctricas cardíacas en sus diferentes componentes de frecuencia, lo que facilita la detección de irregularidades en el ritmo y permite la evaluación de la variabilidad de la frecuencia cardíaca (HRV) [3]. En este contexto, la máxima frecuencia se convierte en un indicador clave, ya que revela la frecuencia predominante en relación con la potencia total de la señal. En otras palabras, esta frecuencia máxima representa el ritmo que prevalece en el comportamiento cardíaco y se manifiesta de manera distintiva en cada una de las enfermedades cardíacas, lo que contribuye a un diagnóstico más preciso y a la comprensión de las características específicas de cada patología.

Por otro lado, para llevar a cabo un análisis eficaz, es fundamental realizar un adecuado procesamiento de los datos. Esto incluye el filtrado y suavizado de las señales, donde filtros digitales pasa altas, pasa bajas y diversas transformaciones de la señal juegan un papel crucial [4]. En este informe, se reportará el procesamiento de un conjunto de señales de ECG de la segunda derivación, tanto para pacientes con SB como para aquellos con AFIB. Posteriormente, se compararon estos datos con un conjunto de señales ya previamente filtradas. El objetivo de esta comparación es evaluar las diferencias en la máxima frecuencia cardíaca entre los datos originales y los filtrados, así como entre las distintas técnicas de filtrado aplicadas, con el fin de identificar las discrepancias y obtener conclusiones sobre la efectividad de los métodos utilizados.

MARCO TEÓRICO

A. *Bradicardia Sinusal*

La Bradicardia Sinusal (SB) es un tipo de arritmia que se origina en el nodo sinusal del corazón, el cual actúa como el marcapasos natural, estableciendo el ritmo de las pulsaciones eléctricas que controlan el bombeo cardíaco en cada zona del corazón. Esta condición afecta principalmente la frecuencia cardíaca, reduciendo el número de latidos por minuto en comparación con sujetos sanos. A diferencia de otras arritmias, la Bradicardia Sinusal no provoca irregularidades en las pulsaciones, ya que los patrones del ritmo cardíaco suelen ser constantes, sin cambios aleatorios en la frecuencia de la actividad eléctrica [5].

Una de las causas más comunes de la bradicardia es una disfunción del nervio vago. El nodo sinoauricular está regulado por los sistemas nerviosos simpático y parasimpático, los cuales modulan la frecuencia cardíaca según las necesidades del organismo. Esta regulación constante asegura que el corazón se ajuste a las demandas del cuerpo, pero cuando el equilibrio entre ambos sistemas se ve alterado, pueden surgir problemas como la bradicardia.

En términos clínicos, la Bradicardia Sinusal puede ser asintomática en muchos casos, pero cuando la frecuencia cardíaca desciende por debajo de ciertos niveles críticos (generalmente menos de 50 latidos por minuto), los pacientes pueden experimentar fatiga, mareos, desmayos o falta de aire. Estas manifestaciones son el resultado de un flujo sanguíneo insuficiente para satisfacer las demandas de los órganos y tejidos del cuerpo, en especial el cerebro [5]. Por tanto, aunque no siempre representa una emergencia médica, la SB puede ser indicativa de un problema subyacente que requiere atención, especialmente en personas mayores o en aquellos con enfermedades cardiovasculares.

B. *Fibrilación Auricular*

La Fibrilación Auricular (AFIB) es un tipo de arritmia cardíaca que se caracteriza por un aumento en la frecuencia cardíaca y la presencia de impulsos eléctricos irregulares y descoordinados. Esto significa que los latidos del corazón suelen ser mucho más rápidos en comparación con los de un paciente sano y, además, tienden a ser erráticos, con variaciones irregulares en la frecuencia, completamente aleatorias [6]. La causa principal de este comportamiento radica en las aurículas, especialmente en la aurícula derecha, donde las contracciones se vuelven rápidas y descoordinadas, interfiriendo con el ritmo de los ventrículos. Esta falta de sincronización afecta el flujo sanguíneo, reduciendo la eficiencia en el transporte de oxígeno y la circulación general del cuerpo.

El origen de este comportamiento desorganizado se debe a impulsos eléctricos descoordinados que no son controlados por el nodo sinusal, el marcapasos natural del corazón. En lugar de seguir el ritmo regular que debería coordinar las contracciones de las aurículas con los ventrículos, las aurículas laten a su propio ritmo, completamente desincronizadas del resto del corazón. Estos impulsos eléctricos irregulares pueden surgir debido a diversas causas, como la hipertensión arterial, que provoca cambios en el tejido de las aurículas, haciendo que se vuelva más rígido y afecte la transmisión de impulsos eléctricos [6]. También las enfermedades de las válvulas cardíacas, como la estenosis mitral, pueden agrandar las aurículas, generando condiciones que favorecen la aparición de impulsos irregulares. Otras causas incluyen la insuficiencia cardíaca, el hipertiroidismo, el consumo excesivo de alcohol o drogas, las inflamaciones cardíacas, como la pericarditis, y el envejecimiento, que debilita el sistema eléctrico del corazón con el tiempo.

C. *Diferencias Importantes*

En cuanto a la diferencia en la regularidad del ritmo entre la Bradicardia Sinusal (SB) y la Fibrilación Auricular (AFIB), es importante destacar que en la SB el ritmo cardíaco es regular, aunque más lento de lo normal. Los latidos se producen a intervalos constantes, manteniendo un patrón predecible, ya que el nodo sinusal sigue siendo el marcapasos que controla de manera ordenada la frecuencia de las contracciones del corazón, aunque a un ritmo más bajo.

Por el contrario, en la AFIB el ritmo cardíaco es completamente irregular y caótico. Las aurículas laten de manera descoordinada y la frecuencia varía de manera errática, sin seguir un patrón establecido. Esto se debe a que los impulsos eléctricos que controlan las contracciones auriculares no provienen del nodo sinusal, lo que provoca una falta de sincronización con el resto del corazón. En consecuencia, mientras que la Bradicardia

Sinusal afecta la frecuencia de los latidos pero mantiene la regularidad, la Fibrilación Auricular altera tanto la frecuencia como la regularidad del ritmo cardíaco, lo que genera un latido desorganizado y menos eficiente

D. Filtros Lineales

En el procesamiento de señales digitales, el filtrado es una operación fundamental que utiliza técnicas de filtrado para mejorar o modificar la calidad de una señal. Los filtros se emplean principalmente para reducir el ruido presente en la imagen, preservando su contenido visual [7]. La selección del filtro depende del tipo de tarea y de las características de los datos.

En sistemas lineales, los principios de escalamiento y superposición son fundamentales para entender su comportamiento:

1. **Escalamiento:** En un sistema lineal, la amplitud de la señal de salida es proporcional a la amplitud de la señal de entrada. Esto significa que si se multiplica la entrada por una constante, la salida también se escala en la misma proporción [8].
2. **Superposición:** Este principio establece que si se suman dos señales y se introducen juntas en un filtro lineal, la salida es equivalente a la suma de las salidas que se obtendrían si cada señal hubiese sido filtrada por separado. Esto permite analizar señales complejas dividiéndolas en componentes más simples [8].

Los filtros lineales tienen diversas aplicaciones en el procesamiento de señales y datos, destacándose en suavizado y desenfoque de imágenes para reducir ruido y detalle mediante filtros como el Gaussiano; en comunicación, donde eliminan componentes no deseados de la señal transmitida; y en detección de bordes, donde filtros como el Sobel resaltan cambios de intensidad en la imagen. Además, en el análisis de series temporales, estos filtros suavizan datos para destacar tendencias, y en el procesamiento de audio equilibran el sonido, eliminando ruido o amplificando frecuencias específicas [7]. Estas aplicaciones muestran la versatilidad de los filtros lineales en la mejora de calidad y precisión en distintos contextos de procesamiento.

E. Filtros No Lineales

El filtrado no lineal es una técnica fundamental para la estimación en línea de variables ocultas dinámicas a partir de datos entrantes, con aplicaciones en diversas áreas como la ingeniería, el aprendizaje automático y las ciencias naturales. Este proceso puede considerarse una extensión de la inferencia bayesiana estática, evolucionando hacia modelos en tiempo discreto, frecuentemente utilizados en aprendizaje automático, y más adelante, hacia la teoría de filtrado en tiempo continuo. Un concepto central en esta teoría es el cambio de medida de probabilidad, que facilita la conexión entre los problemas en tiempo discreto y continuo, y entre diferentes modelos de observación. Esta noción también es crucial en la construcción de algoritmos de filtrado de partículas, empleados en sistemas complejos para la estimación eficiente de estados ocultos [9]

En el contexto del procesamiento de señales, los filtros no lineales ofrecen ventajas sustanciales en comparación con los filtros lineales, especialmente en aplicaciones que requieren un tratamiento preciso y adaptativo. Estos filtros son más robustos al ruido, siendo capaces de eliminar ciertos tipos de interferencias sin degradar la calidad de la señal o imagen. Esto los convierte en herramientas ideales para preservar detalles cruciales, como en el caso de imágenes médicas o señales de comunicación [10].

Además, los filtros no lineales son capaces de restaurar señales distorsionadas de manera no lineal, un proceso que excede las capacidades de los filtros lineales. Esta propiedad les permite reconstruir señales que han sufrido alteraciones complejas, algo que no es posible con filtros tradicionales. Asimismo, su adaptabilidad les permite ajustarse a las características locales de la señal, proporcionando una flexibilidad superior en el tratamiento de datos complejos y heterogéneos [10].

En procesamiento de señales biomédicas, estos filtros son particularmente valiosos para realizar características importantes en imágenes médicas y eliminar artefactos en señales biomédicas, mejorando así la calidad y precisión en diagnósticos y análisis médicos. Esta capacidad es crucial en campos como la neurociencia, la cardiología y otras áreas de la medicina, donde los datos ruidosos y complejos deben ser tratados de manera precisa para obtener diagnósticos exactos

METODOLOGÍA

Para el desarrollo de este proyecto, se emplearon dos conjuntos de datos extraídos de una base de datos especializada en señales de ECG de diversas patologías. En este caso, se seleccionaron únicamente las patologías de Bradicardia Sinusal (SB) y Fibrilación Auricular (AFIB), con un total de 3,889 señales para SB y 1,780 para AFIB. Ambas series de datos estaban muestreadas a una frecuencia de 500 Hz y contenían 5,000 muestras por señal [11]. Para optimizar el análisis, se trabajó exclusivamente con la segunda derivación de las 12 disponibles para cada patología.

Los datos se organizaron en dos categorías: una con señales previamente filtradas y otra con señales en su estado original, caracterizadas por un alto nivel de ruido. Ambas categorías contenían los mismos registros para cada patología, lo que permitió una comparación directa entre los datos filtrados experimentalmente y aquellos ya procesados en la base de datos, facilitando así el análisis del impacto del filtrado en los resultados estadísticos.

Para el proceso experimental, se seleccionaron los archivos sin ningún tipo de filtrado y se aplicaron herramientas de filtrado digital lineales (como los filtros FIR e IIR) y no lineales (como el filtrado por Wavelets). Se diseñaron tres flujos de trabajo (ver Tabla 1), cada uno basado en diferentes combinaciones de estas herramientas, con el objetivo de identificar el filtrado más adecuado sin pérdida significativa de información. Para evaluar la eficacia de cada flujo, se tomó una muestra de 10 señales de cada patología, permitiendo analizar la eficiencia en este subconjunto antes de aplicarlo a la población completa de señales.

TABLA 1

Flujo_1	Flujo_2	Flujo_3
Pasa Altas de 0.5 Hz con un Filtro Digital Tipo IIR de Orden 2	Detrend de tendencia lineal	Pasa Altas de 0.5 Hz con un Filtro Digital Tipo IIR de Orden 2
Wavelet con la señal Bior6.8	Wavelet con la señal Bior6.8	Pasa Bajas de 50 Hz con un Filtro Digital FIR de Orden 101
Pasa Bajas de 50 Hz con un Filtro Digital FIR de Orden 101	Pasa Bajas de 50 Hz con un Filtro Digital FIR de Orden 101	

Tabla 1. Flujos aplicados en el proyecto 3

Antes de realizar el análisis, se definieron cuidadosamente los parámetros específicos para cada filtro en los distintos flujos de trabajo, asegurando un diseño adecuado para la señal ECG. En el caso de los filtros pasa altas y pasa bajas, se utilizaron frecuencias de corte de 0.5 Hz y 50 Hz, respectivamente. Se optó por un enfoque mixto: un filtro IIR para bajas frecuencias, debido a su eficiencia computacional y estabilidad, y un filtro FIR para altas frecuencias, aprovechando su precisión de fase y la estabilidad en la frecuencia de corte alta.

La selección de cada filtro se justificó con el diagrama de Bode (ver Figura 1), que muestra las respuestas en fase y amplitud. En este diagrama, se observó que los filtros FIR ofrecen una mayor estabilidad en la fase a frecuencias altas, mientras que los filtros IIR son más eficaces para bajas frecuencias. En los filtros FIR, se utilizó una ventana Hamming para optimizar la estabilidad y atenuación, con un orden entre 100 y 110, ajustado en función del ancho de banda de rechazo requerido. Para los filtros IIR, se seleccionó un filtro de bajo orden (tipo 2) y una aproximación Butterworth, ideal para señales de ECG, ya que permite reducir el ruido sin afectar significativamente la fase en la banda pasante.

Para el filtro no lineal basado en Wavelets, se definieron parámetros específicos que permitieron optimizar el proceso de reducción de ruido en la señal de ECG. Se utilizó la familia Bior 6.8, conocida por su alta compatibilidad con señales biomédicas, y particularmente con el ECG, debido a su capacidad para preservar la

estructura de la señal [12]. Esta elección es comparable con las alternativas Sym 6 y Db6, las cuales son comúnmente empleadas en este tipo de análisis por su capacidad para adaptarse a la morfología de la señal y su efectividad en la reducción de ruido.

Los niveles de descomposición del filtro se ajustaron de acuerdo con el tamaño de la señal y las propiedades del wavelet, permitiendo una representación precisa de los detalles finos y las tendencias en diversas frecuencias. Para reducir el ruido sin comprometer información clave, se aplicó un umbral de atenuación adaptable al tamaño de los datos (ver Ecuaciones 1 y 2), que facilitó la separación entre los componentes de baja frecuencia (asociados con la forma suave de la señal) y aquellos de alta frecuencia, donde generalmente se encuentra el ruido. Esta técnica asegura una limpieza efectiva de la señal, conservando las características esenciales del ECG y mejorando su precisión para análisis clínicos.

$$\lambda = \sqrt{2 \log(N)}:$$

$$\sigma = \frac{\text{mediana}(dk)}{0.6745}$$

Por otro lado, la evaluación de los flujos de filtrado se realizó a partir de varios métodos de análisis. Primero, se visualizaron las señales ploteadas para observar la suavidad de sus trazos, y luego se aplicaron correlaciones con las señales previamente filtradas en la base de datos para asegurar que no hubiera pérdida de información relevante (ver figura 2). Finalmente, se compararon con la señal en su estado ruidoso original, lo que ayudó a identificar qué filtro lograba una atenuación de ruido efectiva, manteniendo la fidelidad de la señal ECG sin filtrar (Ver figura 3).

Con base los resultados de cada flujo, se seleccionó el segundo proceso de filtrado, debido a su alta correlación con la forma de la señal, que es superior al flujo 1, en la gran mayoría de las señales de la muestra analizada, además de su baja correlación con respecto al ruido a diferencias de los demás flujos, también se observa una mayor suavidad en la señal a diferencia del flujo 3, esto debido a la aplicación de los filtros wavelet, aunque para señales totalmente distorsionadas debido a problemas de medición suele ser muy ineficiente, en la mayor parte de las señales cumple con un excelente preservación de la forma de ECG original.

Después de aplicar el filtrado al conjunto de señales sin procesar, se obtuvo el espectro de potencia para cada conjunto de datos: tanto el filtrado experimentalmente como el previamente filtrado en la base de datos. Este análisis permitió extraer, para cada señal, la frecuencia con la máxima potencia o la mayor representación de energía, diferenciada para cada patología. Los valores de frecuencia máxima obtenidos fueron luego almacenados y preparados para un análisis estadístico comparativo entre los conjuntos de cada patología.

Para la fase descriptiva, se utilizaron gráficos de cajas y bigotes, gráficos de violín e histogramas que permitieron observar la distribución de las frecuencias máximas y evaluar tanto la periodicidad como la tendencia de estos valores en cada proceso de filtrado y para cada patología. Estos gráficos facilitaron la visualización de patrones y variaciones entre los diferentes conjuntos.

En la fase inferencial, se aplicaron pruebas de normalidad a los datos mediante tres supuestos:

1. **Supuesto de normalidad mediante la prueba de Kolmogorov-Smirnov**
 - **Hipótesis nula (H_0):** Los datos provienen de una distribución normal.
 - **Hipótesis alternativa (H_1):** Los datos no provienen de una distribución normal.
2. **Supuesto de Homocedasticidad mediante la prueba de Levene**
 - **Hipótesis nula (H_0):** los datos poseen homocedasticidad.
 - **Hipótesis alternativa (H_1):** Los datos no poseen homocedasticidad.

Cada prueba de normalidad indicó que los datos no seguían una distribución normal, lo cual llevó a utilizar análisis inferenciales no paramétricos. En este contexto, se aplicó la prueba U de Mann-Whitney para comparar las medianas de las frecuencias máximas de potencia entre los conjuntos de señales filtradas experimentalmente

y las filtradas previamente en la base de datos, diferenciando entre las dos patologías (Bradicardia Sinusal y Fibrilación Auricular).

Las hipótesis para esta prueba fueron las siguientes:

- **Hipótesis nula (H_0):** No hay diferencias significativas entre las medianas de las frecuencias máximas de potencia en los conjuntos de señales para cada patología, lo que sugeriría que el tipo de filtrado no afecta a este parámetro.
- **Hipótesis alternativa (H_1):** Existen diferencias significativas entre las medianas de las frecuencias máximas de potencia en los conjuntos de señales, lo que indicaría una posible influencia del tipo de filtrado sobre este parámetro.

Este análisis permitió evaluar si el filtrado afectaba las frecuencias máximas, y si podría existir una relación entre estas frecuencias y el tipo de proceso de filtrado aplicado a las señales, considerando que ambos conjuntos de datos partían de las mismas señales originales. Los resultados del test U de Mann-Whitney ofrecieron una visión clara sobre la homogeneidad o variación en el parámetro de frecuencia máxima entre los dos métodos de filtrado, ayudando a concluir si el filtrado experimental modifica la estructura de la señal de manera significativa en comparación con el filtrado previo.

RESULTADOS

A. *Bode*

Para diferenciar la función de filtrado, se utiliza un diagrama de Bode, con el objetivo de analizar cómo se comportan la fase y la magnitud en las frecuencias de corte deseadas. Tras este análisis, se describen los resultados de ambos filtros. El filtro con frecuencia de corte baja de 0.5 Hz, considerado como un filtro pasa altas, presenta las siguientes características

1. Filtro FIR: Este filtro mantiene una magnitud constante en la banda pasante, con un leve rizado. La fase, por su parte, adopta una forma sinusoidal que varía entre 100 y -100 grados, afectando la fase de todas las frecuencias de la señal.
2. Filtro IIR: En este caso, no se observa rizado en la banda pasante. La fase experimenta un cambio de 0 a 150 grados, pero en un rango estrecho, sin afectar la fase de otras frecuencias.

Al analizar lo que ocurre en 50 Hz, se considera un filtro pasa bajas.

1. El filtro FIR presenta una atenuación aproximada de -50 dB, con un pronunciado rizado en la banda de rechazo. Este rizado varía hasta 50 dB. En cuanto a la fase, sigue una forma sinusoidal, pero en este caso se observa una combinación de varias frecuencias, similar a una suma de sinusoides, que varía de manera similar a la forma sinusoidal en todas las frecuencias de la señal.
2. El filtro IIR comienza a atenuarse mucho antes de los 50 Hz, mostrando una pendiente gradual hasta alcanzar una atenuación máxima a 0 Hz. En cuanto a la fase, se evidencia una variación suave de 0 a -150 grados a lo largo de las frecuencias de la señal

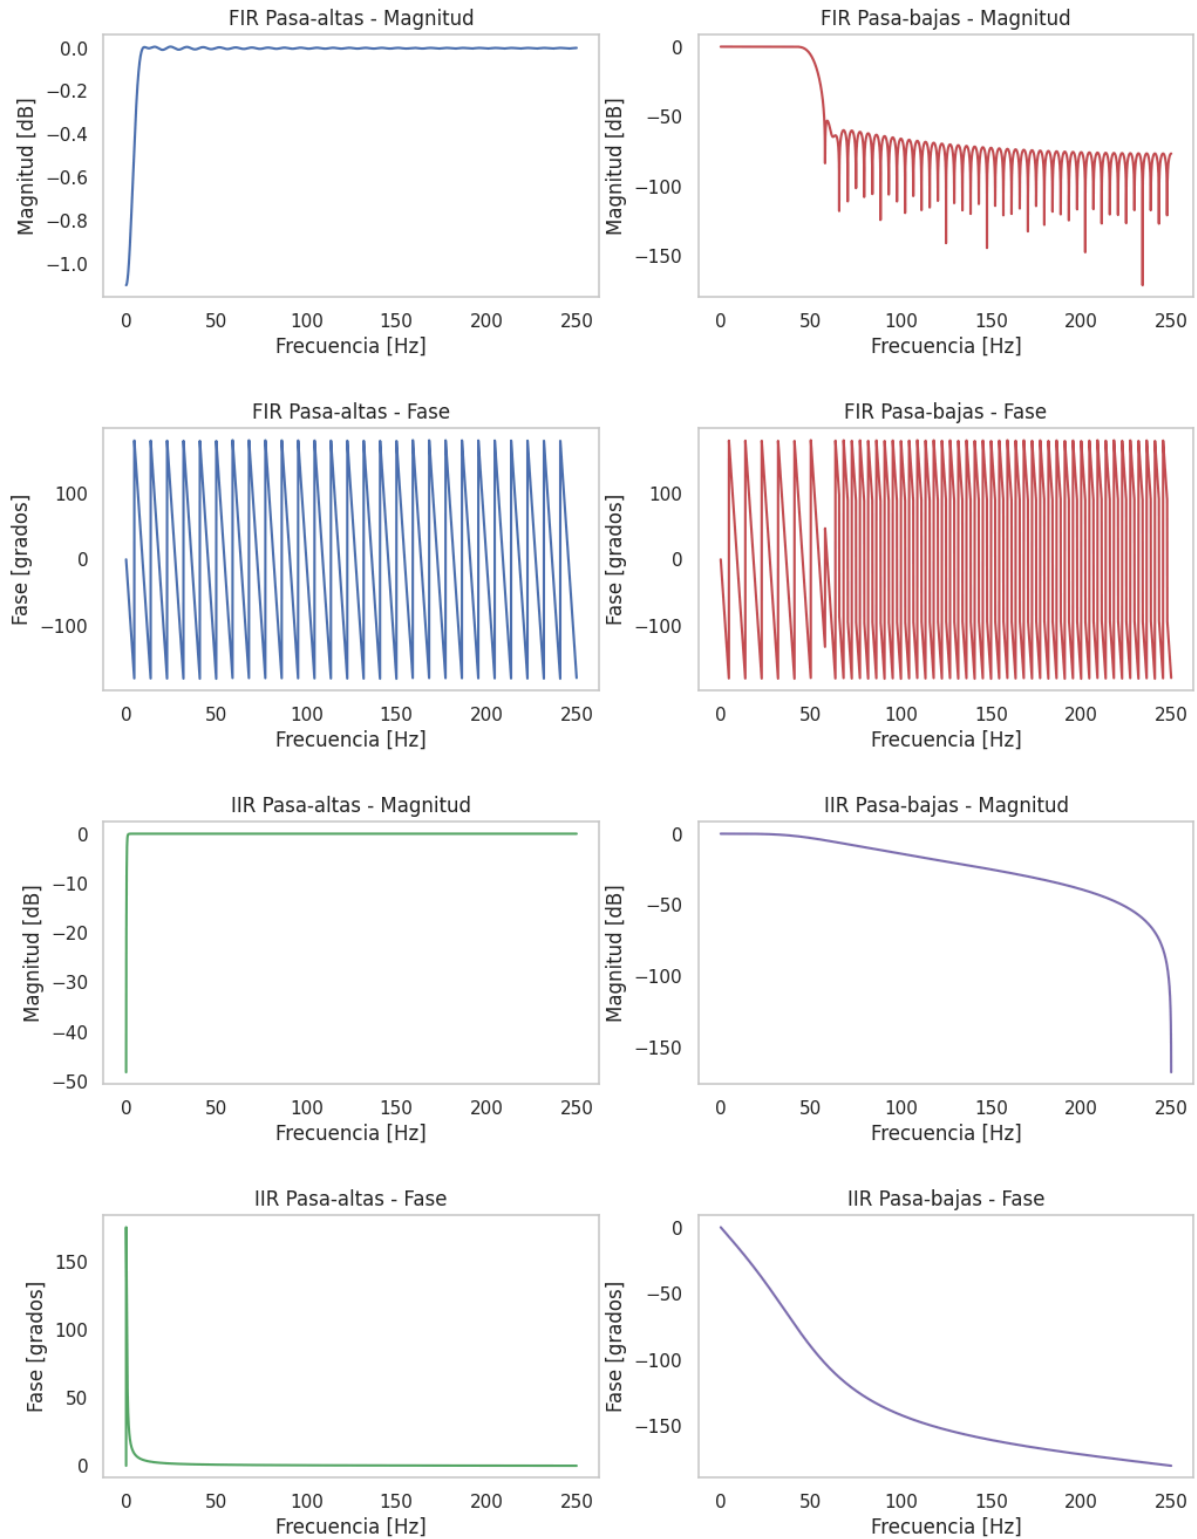


Figura 1. Diagramas de Bode en fase y magnitud de los filtros IIR y FIR en las frecuencias de corte 0.5 y 50 Hz

B. Flujos y Señal con y sin Filtrado

La comparación entre las señales obtenidas de los flujos 1, 2 y 3, y las señales analizadas en el Proyecto 2 (P2), proporciona hallazgos relevantes. En términos generales, todos los flujos logran capturar el ritmo de la señal, y aunque las señales filtradas coinciden con los picos principales de la señal original, se observan variaciones en

la forma en que cada flujo maneja el ruido y los detalles más finos. Un aspecto destacable es que algunos flujos muestran un leve desplazamiento temporal, lo cual podría ser una característica inherente a ciertos tipos de filtros




Figura 2. correlación de los flujos con la señal filtrada P2

El flujo 3 sobresale por su alta similitud con la señal de P2, exhibiendo una correlación superior a la de los otros flujos. Sin embargo, también es el flujo que presenta el mayor nivel de ruido en las señales. En cuanto a los flujos 1 y 2, ambos muestran análisis similares, aunque el flujo 2 tiene una correlación ligeramente más alta que el flujo 1. A diferencia del flujo 3, tanto el flujo 1 como el flujo 2 presentan señales más suaves y limpias, lo que sugiere un manejo más eficiente del ruido.

Un aspecto crucial que se destaca es la eliminación de la tendencia de la señal en el flujo 2, lo que previene que este flujo pierda la relación con la señal original de ECG, mejorando así la precisión en la detección de los picos. Esta eliminación de la tendencia resulta fundamental para evitar que el filtro siga la variabilidad de la señal original de manera errónea.




Figura 3. correlación de los flujos con la señal sin filtrar P3

Cuando se compara el rendimiento de los flujos con las señales sin filtrar del Proyecto 3, se observa que el flujo 3 mantiene una correlación más alta en comparación con los otros flujos, comprobando su poca atenuación contra el ruido. Sin embargo, se confirma la tendencia de que el flujo 2 tiene una correlación ligeramente superior al flujo 1. Además, se reafirma la importancia de la eliminación de tendencia, ya que este aspecto permite que el flujo 2 conserve mejor las características fundamentales de la señal original sin amplificar el ruido o los artefactos.

C. Estadística Descriptiva

Para el análisis descriptivo del flujo 2, los resultados obtenidos indican diferencias significativas entre los datos del proyecto 2 y el proyecto 3 en ambas patologías (ver Figura 4). Esto sugiere que el comportamiento de las señales en cada proyecto es distinto, posiblemente debido a las variaciones en las características de las señales o en los parámetros de filtrado aplicados. A pesar de haber seleccionado el filtro óptimo basado en los criterios establecidos, se observa que las medias de ambas patologías en el flujo 2 son notablemente menores en comparación con las señales filtradas del proyecto 2.

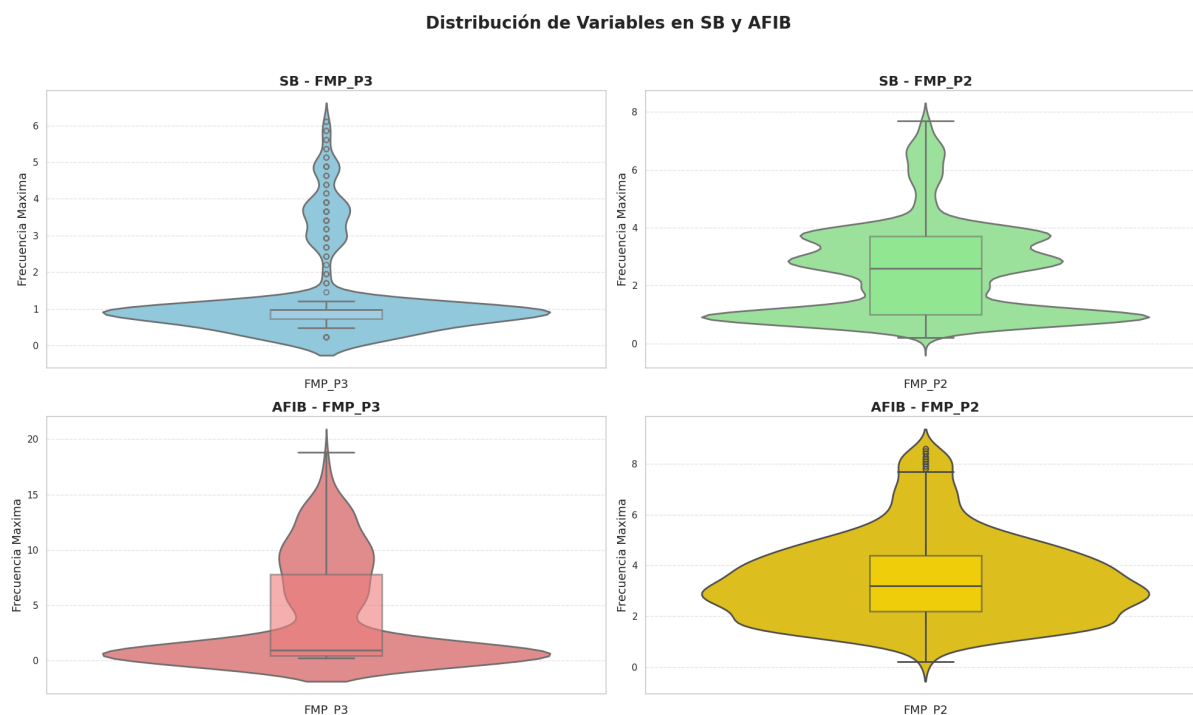


Figura 4. Gráfica de Cajas y Bigotes de las patologías SB y AFIB de la distribución de las frecuencias máximas en el proyecto 2 y 3

Además, se identifican variaciones en la dispersión de los datos entre las patologías. En el caso de Bradicardia Sinusal (SB), las cajas en el gráfico de flujo 2 presentan un tamaño reducido en comparación con las del proyecto 2, lo que indica una menor variabilidad en las señales. Contrariamente, para Fibrilación Auricular (AFIB), la caja en el flujo 2 es considerablemente más grande, lo que refleja una mayor dispersión en los datos. Estas diferencias en el tamaño de las cajas sugieren que el flujo 2 afecta de manera diferenciada a cada patología, destacando la importancia de ajustar los parámetros de filtrado según las características específicas de las señales y las necesidades de cada análisis.

En los histogramas (ver Figura 5), se aprecia con mayor claridad la dispersión de los datos, mostrando cómo estos se distribuyen en el dominio de la frecuencia. Cada patología fue evaluada de manera independiente, y los resultados coinciden con las observaciones del gráfico de cajas y bigotes: la dispersión de datos en el caso de Fibrilación Auricular (AFIB) es considerablemente mayor en el flujo 2, lo que indica una variabilidad amplia en las frecuencias presentes en esta patología. En contraste, para Bradicardia Sinusal (SB), la dispersión es menor en el flujo 2 y parece estar influenciada por las señales previamente filtradas en el proyecto 2, las cuales presentan una menor variabilidad. Estos patrones de dispersión resaltan cómo las características de frecuencia y variabilidad en cada patología responden de forma distinta a los procesos de filtrado y análisis empleados en los distintos flujos de trabajo.

Además, se observa una moda muy pronunciada en las frecuencias bajas para ambas patologías en el flujo 2, lo que sugiere una mayor concentración de frecuencias en este rango al aplicar el filtro seleccionado. En comparación, esta tendencia no era tan evidente en el análisis de los datos filtrados en otros flujos, donde la distribución de frecuencias parecía estar más dispersa y no presentaba un pico tan marcado en las bajas frecuencias. Esta diferencia en la moda puede estar relacionada con la respuesta particular del filtro de flujo 2, el cual podría estar optimizando la captura de componentes de baja frecuencia, características tanto de la Bradicardia Sinusal (SB) como de la Fibrilación Auricular (AFIB).




Figura 5. Histogramas de las patologías SB y AFIB de la distribución de las frecuencias máximas en el proyecto 2 y 3

D. Estadística Inferencial

En el análisis estadístico inferencial, se obtuvieron los siguientes resultados en los dos supuestos clave de normalidad. En el primer supuesto, se evaluó la distribución de cada uno de los segmentos de información correspondientes a las señales del proyecto 2 y 3, considerando específicamente las patologías de Bradicardia Sinusal (SB) y Fibrilación Auricular (AFIB). Los resultados revelaron que ninguno de los segmentos presentó una distribución normal de los datos (ver Tabla 2). Asimismo, en el análisis de homocedasticidad, se encontró que ambas patologías mostraban una variabilidad inconsistente, indicando heterocedasticidad en ambas condiciones (ver Tabla 3). Con base en estos hallazgos, se concluyó que la prueba estadística más adecuada era una prueba no paramétrica, seleccionando la prueba U de Mann-Whitney para la comparación de medianas.

En el análisis mediante la prueba no paramétrica, se evaluó el comportamiento de las medianas de las señales en ambos proyectos para cada patología (SB y AFIB) (Ver Tabla 4). Los resultados indicaron que las patologías no presentaban una distribución similar en sus medianas; es decir, existían diferencias significativas entre las medianas de ambas condiciones. Este hallazgo sugiere que los datos varían notablemente entre los tipos de filtrado aplicados en cada proyecto, mostrando un comportamiento diferenciado en cada patología. Estas diferencias respaldan la necesidad de análisis específicos para cada condición, dada la variabilidad detectada en las respuestas de las señales bajo distintos métodos de filtrado.

TABLA 2

Estado	Variable	Statistic	p-value	Normalidad
SB	FMP_P3	0,3879663001	0,0000	Se rechaza H0
SB	FMP_P2	0,2040676736	0,0000	Se rechaza H0
AFIB	FMP_P3	0,2549660385	0,0000	Se rechaza H0
AFIB	FMP_P2	0,1847147067	0,0000	Se rechaza H0

Tabla 1. Resultados de la prueba Kolmogorov

TABLA 3

Enfermedad	Variable	Statistic	p-value	Homocedasticidad
SB	FMP_P3 vs FMP_P2	4,165304835	0,0412936847888 44700	Se rechaza H0
AFIB	FMP_P3 vs FMP_P2	193,2206657	0,00000	Se rechaza H0

Tabla 3. Resultados de la prueba Levene

TABLA 4

Variable	U-statistic	p-value	Igualdad de Medianas
SB	4987803	0,00000	Se rechaza H0
AFIB	1202455	0,00000	Se rechaza H0

Tabla 4. Resultados de la prueba no paramétrica U

ANÁLISIS

A. Bode

En el análisis de los diagramas de Bode, se observó que los filtros IIR y FIR poseen características distintas en cuanto a orden y eficiencia. Los filtros IIR requieren órdenes más bajas, aunque implican un costo computacional mayor; en cambio, los filtros FIR, a pesar de necesitar órdenes más altas, ofrecen estabilidad en fase y magnitud en frecuencias elevadas [13].

Los resultados mostraron que los filtros IIR mantienen estabilidad en frecuencias bajas, aunque pierden precisión de fase a frecuencias altas. Por el contrario, los filtros FIR conservan una respuesta de fase lineal en frecuencias altas, aunque con un mayor procesamiento. Con base en esto, se optó por una estrategia combinada: filtros IIR para altas frecuencias y FIR para bajas, aprovechando así las ventajas específicas de cada uno [14].

B. Selección de flujos

Como se describió en la sección de resultados, la selección de datos se llevó a cabo evaluando las correlaciones con las señales filtradas del Proyecto 2. En particular, se analizó cómo el ruido afectaba los flujos 1 y 3. En ambos casos, se observó una caída en la señal, generalmente en los extremos, posiblemente debido a la falta de aplicación de la técnica *detrend* en estas señales, la cual solo fue implementada en el flujo 2 para ajustar la tendencia de los datos y reducir los efectos de deriva. La eliminación de tendencia es crucial en el análisis de señales, ya que ayuda a eliminar componentes de baja frecuencia que pueden distorsionar la correlación temporal.

En el flujo 1, se utilizó la técnica *wavelet*, que fue efectiva para reducir el ruido, pero esta aproximación también implicó una leve pérdida de la forma original de la señal debido a las aproximaciones inherentes a la transformación wavelet [15]. Las técnicas de wavelet pueden ser útiles en la representación multiescalar, permitiendo el ajuste fino de frecuencias específicas; sin embargo, la descomposición por wavelet puede alterar en parte la estructura de la señal en función del nivel de detalle utilizado. Esta pérdida de detalle resulta en una señal que es menos fiel a la forma original, pero presenta una reducción significativa del ruido.

Por otro lado, el flujo 3, que no utilizó la transformación wavelet, mostró una mayor conservación de la forma original de la señal, aunque también conservaba más ruido, debido a que solo se aplicó un filtro pasa bandas que ignoraba las frecuencias fuera del rango de interés sin reducir el ruido no lineal en la señal [16]. Debido a esto, a pesar de su forma estable, el flujo 3 presentó una alta correlación con la señal ruidosa, afectando la calidad de la correlación en comparación con el flujo 2, el cual se benefició del *detrend* aplicado previamente.

C. Estadística descriptiva

En los gráficos de caja y bigotes, así como en los histogramas presentados en los resultados, se observaron diferencias significativas entre las patologías cuando se aplicaron distintos tipos de filtros en los dos enfoques del proyecto: el flujo de procesamiento seleccionado y el filtrado aplicado previamente en la base de datos.

Para la patología de SB (Sinus Bradycardia), se evidenció una notable reducción en el tamaño de la caja y sus bigotes en las señales filtradas mediante el flujo experimental. Esta reducción puede atribuirse a las características de frecuencia de la SB, que tienden a ser más regulares y uniformes [5]. Como resultado, el filtro experimental, específicamente el flujo 2, demostró ser más efectivo para esta patología, minimizando significativamente la dispersión que inicialmente presentaban las señales de SB. Esto sugiere que el filtro logró un tratamiento más preciso de las variaciones, manteniendo una coherencia que mejora la representación de la señal.

Por otro lado, en el caso de la fibrilación auricular (AFIB), se observó un comportamiento opuesto. Las cajas y bigotes mostraron una dispersión aumentada, lo cual puede deberse a la naturaleza caótica y altamente variable de las señales de AFIB. Esta irregularidad inherente provoca que los datos de la señal difieran considerablemente y, por tanto, el tipo de filtrado aplicado no logre atenuar por completo la variabilidad, aumentando la dispersión observada [6]. Sin embargo, es importante resaltar que la media de la señal en estos casos se mantuvo estable, mostrando valores cercanos a las frecuencias bajas, lo cual es común en el comportamiento de las frecuencias cardíacas. Este hallazgo confirma que, aunque el filtrado pueda manejar las frecuencias predominantes, la variabilidad propia de la señal de AFIB afecta la consistencia del procesamiento de la señal y la uniformidad de los resultados obtenidos.

D. Estadística inferencial

En el análisis de estadística inferencial se observa que, para cada patología, existen diferencias entre las medias de las frecuencias máximas al aplicar los dos tipos de filtros. Esto indica que los filtros afectan de manera diferente el conjunto de datos de cada patología, ya que cada una presenta patrones distintos, especialmente en el dominio de la frecuencia. Estas diferencias en los patrones hacen que los filtros respondan de forma particular a cada conjunto de datos, lo que puede mejorar o empeorar la calidad de la información de las señales según el caso. Así, cada tipo de filtro genera modificaciones específicas en las señales, como también se observó en las pruebas realizadas con los distintos flujos de procesamiento.

Además, se evidencia que este tipo de filtrado es sensible a los cambios en el flujo de datos, lo cual se confirmó con herramientas de filtrado avanzadas como las aproximaciones de wavelet. En señales donde la variabilidad y caoticidad están más presentes, estas aproximaciones resultaron menos efectivas, lo que llevó a una mayor disparidad en los datos. Esto sugiere que las técnicas de filtrado utilizadas no siempre son óptimas para señales con alta irregularidad, ya que no logran minimizar suficientemente la dispersión o el ruido en este tipo de datos.

CONCLUSIONES

- Diferencias en la eficiencia de los filtros: Los filtros IIR y FIR mostraron distintas características en cuanto a orden y eficiencia. Los IIR, a pesar de requerir órdenes más bajos y ser efectivos en frecuencias bajas, pierden precisión de fase en frecuencias altas. Los FIR, aunque necesitan un orden más alto, conservan una respuesta de fase lineal en frecuencias elevadas, lo que justifica el uso de una estrategia combinada para aprovechar las ventajas de ambos.

- Impacto del filtrado en la morfología de las señales: El análisis evidenció que el flujo de procesamiento y las técnicas de filtrado aplicadas afectan la estructura de la señal de manera diferente. Por ejemplo, la técnica wavelet aplicada en el flujo 1, aunque efectiva para reducir el ruido, conlleva una leve alteración en la forma original de la señal, mientras que el flujo 3, sin wavelet, conserva mejor la forma, pero con más ruido.
- Adaptabilidad de los filtros según la patología: La respuesta al filtrado varía según la patología. En el caso de la SB, los filtros utilizados en el flujo experimental lograron minimizar la dispersión de los datos, lo que indica un tratamiento más coherente de la señal. En contraste, las señales de AFIB, debido a su naturaleza caótica, experimentaron mayor dispersión tras el filtrado, demostrando que los métodos aplicados no siempre son eficaces para patologías con alta variabilidad.
- Sensibilidad a la variabilidad de la señal: Las herramientas de filtrado, en especial las aproximaciones wavelet, demostraron ser sensibles a la variabilidad de la señal. Las señales con mayor caoticidad y dispersión, como la AFIB, presentaron limitaciones en la efectividad del filtrado, evidenciando que estas técnicas pueden no ser las más adecuadas cuando se busca una representación fiel y menos ruidosa en contextos de alta irregularidad.

REFERENCIAS

- [1] «Optimal Multi-Stage Arrhythmia Classification Approach | Scientific Reports». Accedido: 7 de noviembre de 2024. [En línea]. Disponible en: <https://www.nature.com/articles/s41598-020-59821-7>
- [2] G. A. Roth *et al.*, «Global Burden of Cardiovascular Diseases and Risk Factors, 1990–2019», *J. Am. Coll. Cardiol.*, vol. 76, n.º 25, pp. 2982-3021, dic. 2020, doi: 10.1016/j.jacc.2020.11.010.
- [3] L. C. M. Vanderlei, C. M. Pastre, R. A. Hoshi, T. D. de Carvalho, y M. F. de Godoy, «Basic notions of heart rate variability and its clinical applicability», *Rev. Bras. Cir. Cardiovasc. Orgao Of. Soc. Bras. Cir. Cardiovasc.*, vol. 24, n.º 2, pp. 205-217, 2009, doi: 10.1590/s0102-76382009000200018.
- [4] S. T. Prasad y D. S. Varadarajan, «ECG Signal Processing Using Digital Signal Processing Techniques», 2013.
- [5] «Detection of Atrial Fibrillation Using a Machine Learning Approach». Accedido: 20 de octubre de 2024. [En línea]. Disponible en: <https://www.mdpi.com/2078-2489/11/12/549>
- [6] «Atrial fibrillation - Symptoms and causes», Mayo Clinic. Accedido: 7 de noviembre de 2024. [En línea]. Disponible en: <https://www.mayoclinic.org/diseases-conditions/atrial-fibrillation/symptoms-causes/syc-20350624>
- [7] A. Jain, «Understanding linear and non linear filters, low pass filter, high pass filter and band pass filter», Medium. Accedido: 7 de noviembre de 2024. [En línea]. Disponible en: <https://medium.com/@abhishekjainindore24/understanding-linear-and-non-linear-filters-low-pass-filter-high-pass-filter-and-band-pass-filter-a704ebbf8996>
- [8] «Linear Filters | Introduction to Digital Filters». Accedido: 7 de noviembre de 2024. [En línea]. Disponible en: https://www.dsprelated.com/freebooks/filters/Linear_Filters.html

- [9] «The Hitchhiker's guide to nonlinear filtering - ScienceDirect». Accedido: 7 de noviembre de 2024. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S0022249619301658#fn12>
- [10] «Nonlinear Filter Definition | DeepAI». Accedido: 7 de noviembre de 2024. [En línea]. Disponible en: <https://deepai.org/machine-learning-glossary-and-terms/nonlinear-filter>
- [11] J. Zheng, «ChapmanECG», jun. 2019, doi: 10.6084/m9.figshare.c.4560497.v1.
- [12] S. Z. Mahmoodabadi, A. Ahmadian, y M. D. Abolhasani, «ECG FEATURE EXTRACTION USING DAUBECHIES WAVELETS».
- [13] Smith, S. W. (2002). *Digital Signal Processing: A Practical Guide for Engineers and Scientists*. Newnes.
- [14] Proakis, J. G., & Manolakis, D. G. (2006). *Digital Signal Processing: Principles, Algorithms, and Applications*. Pearson.
- [15] Smith, S. W. *The Scientist and Engineer's Guide to Digital Signal Processing*. California Technical Publishing, 1997.
- [16] Mallat, S. *A Wavelet Tour of Signal Processing: The Sparse Way*. Academic Press, 2008.